Fase A — Diseño de la bodega de datos

Dataset: *Presuntos Homicidios. Colombia, 2015 a 2024. Cifras definitivas* (Medicina Legal, datos.gov.co)

Alejandra Osorio Giraldo (2266128) · Sebastián Barco (2380599) · Santiago Montoya (2380372) · Laura Rivera (2380712)

1. Propósito y pregunta de negocio

La bodega busca responder: **¿Cuáles son los patrones temporales, geográficos y operacionales de los homicidios en Colombia que permiten identificar zonas de alto riesgo y factores para la prevención del delito?** Para ello se necesita analizar cada homicidio desde cuatro perspectivas: **cuándo** ocurrió, **dónde**, **a quién** le ocurrió y **cómo** ocurrió. Cada perspectiva se convierte en una dimensión.

2. Modelo elegido: esquema estrella

Se eligió un **modelo estrella** con una tabla de hechos central y cuatro dimensiones desnormalizadas. Frente a un copo de nieve, la estrella requiere un solo **JOIN** por dimensión, lo que simplifica las consultas analíticas de la Fase C y mejora su rendimiento. La redundancia que introduce (por ejemplo, repetir el nombre del departamento en cada fila de **dim_geografia**) es pequeña: la dimensión más grande tiene ≈19 mil filas frente a 125 mil hechos.

3. Grano de la tabla de hechos

Una fila de fact_homicidios = una víctima de presunto homicidio registrada por Medicina Legal. Es el nivel más fino disponible en el CSV (columna *ID*, única en los 125.284 registros), por lo que no se pierde información y cualquier agregación (año, departamento, sexo, mecanismo…) se obtiene sumando. La medida **cantidad_homicidios** vale 1 en cada fila y es totalmente aditiva en todas las dimensiones.

4. Diagrama

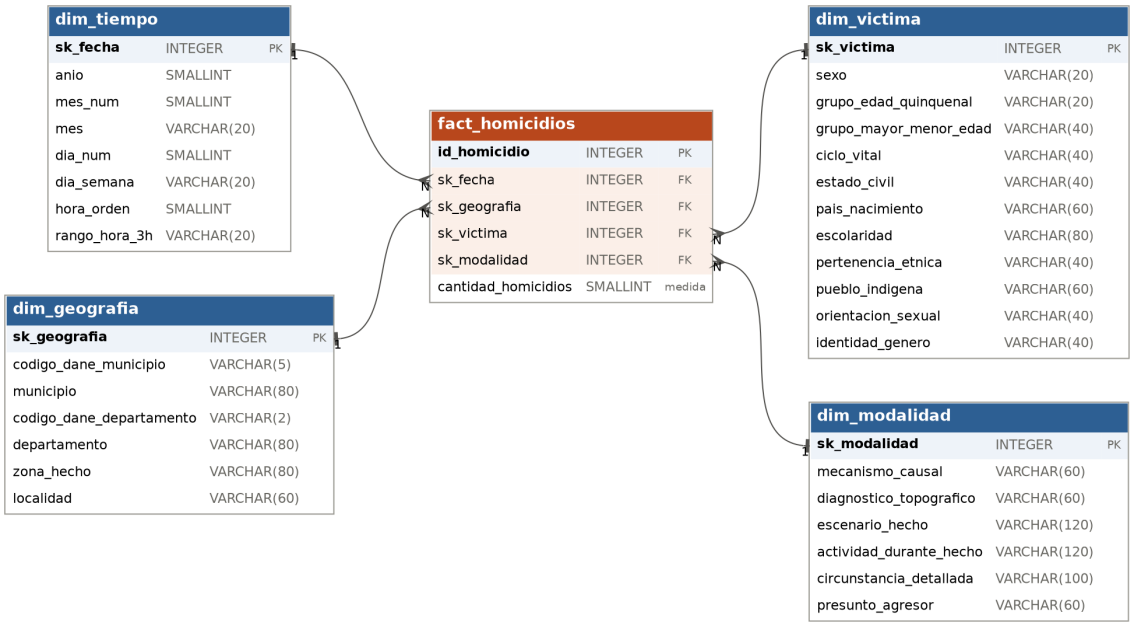


Figura 1. Modelo estrella de la bodega (PK = clave primaria, FK = clave foránea; relaciones 1 a N desde cada dimensión hacia los hechos). Fuente editable: docs/diagrama_bodega.dbml (dbdiagram.io) y docs/diagrama_bodega.dot.

5. Justificación de las dimensiones

Todas las dimensiones usan una **clave subrogada entera** (**sk_***) generada en el ETL, en lugar de claves naturales de texto: son más compactas, aceleran los JOIN y aíslan la bodega de los cambios de escritura del CSV fuente.

Dimensión	¿Por qué existe?	Granularidad (1 fila =)	Atributos
dim_tiempo 7.470 filas	Responde **cuándo**: tendencias anuales, estacionalidad, días y horas de mayor riesgo.	Combinación año × mes × día de la semana × franja de 3 h. El CSV no trae fecha exacta, por eso no hay fecha diaria.	anio, mes, mes_num, dia_semana, dia_num, rango_hora_3h, hora_orden (los *_num/orden permiten ordenar cronológicamente).
dim_geografia 3.046 filas	Responde **dónde**: identificar departamentos y municipios de alto riesgo y la diferencia urbano–rural.	Combinación municipio × zona del hecho × localidad (1.086 municipios DANE).	codigo_dane_municipio, municipio, codigo_dane_departamento, departamento, zona_hecho, localidad (solo Bogotá). Jerarquía departamento → municipio → zona.
dim_victima 10.263 filas	Responde **a quién**: perfil sociodemográfico para focalizar prevención (jóvenes, mujeres, grupos étnicos).	Perfil único de víctima (combinación distinta de sus 11 atributos). No identifica personas.	sexo, grupo_edad_quinquenal, grupo_mayor_menor_edad, ciclo_vital, estado_civil, pais_nacimiento, escolaridad, pertenencia_etnica, pueblo_indigena, orientacion_sexual, identidad_genero.
dim_modalidad 19.266 filas	Responde **cómo**: mecanismo, escenario, circunstancia y agresor, variables operacionales para la prevención.	Combinación única de los 6 atributos del hecho (dimensión tipo *junk* que agrupa descriptores del evento).	mecanismo_causal, diagnostico_topografico, escenario_hecho, actividad_durante_hecho, circunstancia_detallada, presunto_agresor.

6. Columnas del CSV que no se llevaron a la bodega

- **Manera de muerte:** es constante (“1 Presuntos Homicidios” en el 100 % de las filas).
- **Grupo de edad judicial:** redundante con el grupo quinquenal (mismos rangos con cortes judiciales).
- **Pertenencia grupal, Ancestro racial y Transgénero:** 83 categorías muy heterogéneas, o información ya cubierta por pertenencia étnica e identidad de género; se dejan para una iteración futura si alguna pregunta las requiere.

7. Cambios respecto al borrador

Se mantuvo la estructura del borrador (1 hecho + 4 dimensiones). Se estandarizaron los nombres en minúscula *snake_case* (convención de PostgreSQL) y se agregaron a **dim_tiempo** las columnas de orden **mes_num**, **dia_num** y **hora_orden**, necesarias para graficar series y mapas de calor en orden cronológico.