Fase B — Limpieza y normalización: pasos y justificación

Presuntos homicidios en Colombia 2015–2024 · Notebook **entrega/fase_b_limpieza.ipynb**
Alejandra Osorio Giraldo (2266128) · Sebastián Barco (2380599) · Santiago Montoya (2380372) · Laura Rivera (2380712)
Ciencia de Datos — Universidad del Valle, sede Tuluá · Octubre 2026

Resultado: se parte de 125.284 registros × 33 columnas y se obtiene **datos_limpios.parquet** con **124.914 registros × 108 columnas, 0 nulos y 0 duplicados**.

1. Diagnóstico

El CSV no trae nulos explícitos: los faltantes vienen como texto "*Sin información*" (525.641 celdas), "*No había sido implementada*", "*Por determinar*" y "*No aplica*", y se convierten a NaN. No hay filas ni IDs duplicados. Hay inconsistencias de escritura: mayúsculas ("enero"/"Enero"), espacios y comas ("Soltero(a)"/"Soltero (a)"), hora con y sin paréntesis, vocabularios que cambiaron entre años ("Corto punzante"/"Cortopunzante") y municipios con dos nombres ("Cali"/"Santiago de Cali", "Bogotá D.C."/"Bogotá, D.C.").

2. Normalización de texto

Una sola función pasa todo a mayúsculas y unifica espacios y puntuación. Estado civil pasa de 11 a 5 valores, Escenario de 72 a 40, Zona de 5 a 3, Rango de hora de 18 a 8, Mes de 25 a 12 y Mecanismo de 24 a 15. El nombre del municipio se toma del **código DANE** (nombre más frecuente por código), así Cali queda con 11.408 casos en un solo valor.

3. Eliminación de columnas y filas

Qué se eliminó	Por qué
Localidad (90,8 % nulos), Circunstancia (64,5 %), Presunto agresor (51,9 %)	Regla: más del 50 % de nulos. Imputar más de la mitad sería inventar datos.
Orientación sexual, Identidad de género, Transgénero, Pueblo indígena	"No había sido implementada" en la mayoría de los años.
Manera de muerte, Grupo de edad judicial, Pertenencia grupal, Diagnóstico topográfico	Valor único / información repetida / 88 categorías desordenadas / es consecuencia del mecanismo.
98 filas sin municipio (código 999) y 272 con mecanismo "Por determinar"	0,3 % del total. No se pueden ubicar o no tienen variable objetivo; imputar la moda las pondría en Cali sin soporte.

4. Valores nulos — tres estrategias según el tipo de variable

Estrategia	Columnas	Justificación
Moda	Escenario, Zona, Mes, Día, Ciclo vital, Grupo de edad, Mayor/menor, País, Ancestro (0,02 %–8,7 % nulos)	Categóricas con pocos faltantes: la moda casi no altera la distribución. No se usa la media porque no son numéricas.
Mediana	Escolaridad ordinal (21 % nulos)	Es ordinal y sesgada: la mediana (nivel 2, básica primaria) es un nivel real; la media (2,45) no existe.
Categoría "SIN INFORMACIÓN"	Rango de hora (59 %), Actividad (42 %), Pertenencia étnica (38 %), Estado civil (17 %)	Con la moda se inventarían hasta 73.901 horas. Se deja la ausencia como categoría para que el modelo aprenda si es informativa.

5. Valores atípicos — se conservan

Con **IQR**, el 4,5 % de las víctimas (mayores de 59,5 años) sale como atípico, y por municipio hay 122 atípicos; con **Z-score**, 6 municipios tienen $|z| > 3$ (Bogotá, Cali, Medellín, Barranquilla, Cartagena y Cúcuta). **Decisión: se conservan**, porque son edades reales y las grandes ciudades son justo donde

se concentra el problema (≈30 % de los casos). Su efecto se reduce con la transformación logarítmica y el RobustScaler.

6. Codificación de variables categóricas

Técnica	Variables	Por qué
Ordinal Encoding	Grupo de edad (18 niveles), Ciclo vital (6), Escolaridad (8 niveles a partir de 17 escrituras), Mes y Día	Tienen un orden natural de menor a mayor; One-Hot perdería ese orden.
One-Hot (`get_dummies`, `drop_first=True`)	Sexo, Zona, Escenario, Franja horaria, Departamento, Estado civil, Actividad → 78 columnas `oh_`	Nominales sin orden. `drop_first` evita multicolinealidad. Se usa Departamento (33) y no Municipio (1.000+ columnas casi vacías). Los escenarios con < 1.000 casos se agrupan en "OTROS".

7. Transformación y escalado

Logaritmo: los homicidios por municipio tienen asimetría 16,2; con log(1 + x) baja a 0,46, así que se guarda `homicidios_municipio_log`. **Escalado:** se compararon Min-Max (edad a [0, 1], útil para KNN), Z-score (edad y log de homicidios, media 0 y desviación 1) y RobustScaler (homicidios por municipio, usa mediana e IQR y resiste los extremos).

> **Prevención de data leakage:** el parquet se guarda **sin escalar**. En la Fase C el escalador se ajusta solo con el conjunto de entrenamiento, después del `train_test_split`, y luego se aplica al de prueba.

8. Variable objetivo para la Fase C

`es_arma_fuego` = 1 si el mecanismo fue proyectil de arma de fuego (74,2 % de los casos) y 0 en otro caso (25,8 %). Las clases están desbalanceadas, por lo que en la Fase C se evaluará con F1-score y no solo con accuracy.