Fase C — Modelos predictivos: análisis y modelo elegido

Presuntos homicidios en Colombia 2015–2024 · Notebook **entrega/fase_c_modelos.ipynb**

Alejandra Osorio Giraldo (2266128) · Sebastián Barco (2380599) · Santiago Montoya (2380372) · Laura Rivera (2380712)
Ciencia de Datos — Universidad del Valle, sede Tuluá · Octubre 2026

1. Problema y diseño experimental

Pregunta: ¿se puede anticipar, con las características de la víctima, el lugar y el momento, si un homicidio será cometido con **arma de fuego**? Es una **clasificación binaria** con objetivo `es_arma_fuego` (74,2 % sí, 25,8 % no). Se usan 84 variables: 6 numéricas u ordinales (año, grupo de edad, escolaridad, mes, día, log de homicidios del municipio) y 78 One-Hot (sexo, zona, escenario, franja horaria, departamento, estado civil, actividad).

- **División:** `train_test_split` 80/20 estratificado (99.931 / 24.983 filas), `random_state=42`.
- **Sin data leakage:** el `StandardScaler` se ajusta solo con el conjunto de entrenamiento y todas las métricas se calculan sobre el conjunto de **prueba**.
- **Desbalance:** `class_weight="balanced"` en los tres modelos; la comparación se hace con F1 y ROC-AUC y no solo con accuracy.

2. Tabla comparativa (conjunto de prueba)

Modelo	Accuracy	Precision	Recall	F1	F1 macro	ROC-AUC	Accuracy train
Regresión Logística	0,669	0,845	0,680	0,753	0,627	0,716	0,669
Árbol de Decisión (prof. 10)	0,683	0,825	0,727	0,773	0,624	0,689	0,695
Random Forest (200 árboles)	**0,698**	**0,842**	**0,730**	**0,782**	**0,645**	**0,732**	**0,714**

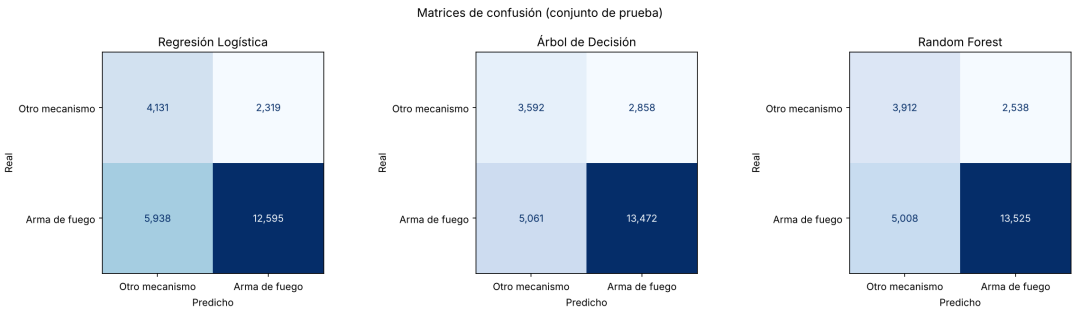


Figura 1. Matrices de confusión de los tres modelos (conjunto de prueba).

Lectura: un modelo trivial que siempre dijera "arma de fuego" tendría 0,742 de accuracy, pero no detectaría ningún caso de otro mecanismo. Los tres modelos detectan entre el 56 % y el 64 % de esos casos y mantienen una precisión de 0,82 a 0,85 para arma de fuego. La diferencia entre entrenamiento y prueba es de 1,6 puntos como máximo, así que no hay sobreajuste.

3. Modelo elegido: Random Forest

> **Por precisión:** es el mejor en 5 de las 6 métricas (accuracy 0,698, recall 0,730, F1 0,782, F1 macro 0,645, AUC 0,732); solo en precision la Regresión Logística lo supera por 0,003. **Por generalización:** la brecha train/test es pequeña (0,714 vs. 0,698). **Por interpretabilidad:** entrega la importancia de cada variable; las más influyentes son la edad, los homicidios del

> municipio, el sexo, el día, el departamento (Bogotá frente a Valle) y el escenario (vía pública frente a vivienda), lo que coincide con los hallazgos de la Fase A.

Alternativas: la Regresión Logística es la más simple de explicar y queda a solo 1,6 puntos de AUC, así que sería la opción si se prioriza la simplicidad. El Árbol de Decisión es fácil de dibujar, pero es el más débil (AUC 0,689).

4. Modelo no supervisado: K-Means sobre 464 municipios

Variables escaladas: log de homicidios, % arma de fuego, % mujeres, % rural y edad promedio (municipios con 30 o más casos). Con k entre 2 y 8, el Silhouette máximo se da en **k = 4**: **Silhouette 0,219** y **Davies-Bouldin 1,40**.

Segmento	Perfil	Ejemplos
Grandes ciudades con arma de fuego	Mediana de 314 casos, 82 % arma de fuego, víctimas de 32 años; concentra el 73 % de los casos	Bogotá, Cali, Medellín, Barranquilla
Rural con más mujeres y víctimas mayores	56 % rural, 12 % mujeres, edad 37 años	San Vicente del Caguán, Puerto Gaitán
Ciudades intermedias con arma blanca	Solo 52 % arma de fuego, 21 % rural	Bucaramanga, Ibagué, Pasto, Manizales
Rural con arma de fuego	57 % rural, 80 % arma de fuego	Ituango, El Tambo, Suárez, Arauquita

5. Limitaciones y mejoras

Un AUC de 0,73 indica un poder predictivo **moderado**: faltan variables clave como el presunto agresor y la circunstancia, que tienen más del 50 % de nulos. Posibles mejoras: buscar hiperparámetros con `GridSearchCV` y validación cruzada, probar Gradient Boosting, agregar variables externas por municipio (población para calcular tasas, presencia de grupos armados, pobreza) y ajustar el umbral de decisión según el costo de cada error.