Homicidios en Colombia 2015–2024: patrones de riesgo a partir de una bodega de datos

Informe del Proyecto 1 — Bodega de datos, ETL y Análisis Descriptivo

Alejandra Osorio Giraldo (2266128) · Sebastián Barco (2380599) · Santiago Montoya (2380372) · Laura Rivera (2380712)

Repositorio: https://github.com/XEBAX10/PROYEC-1-CIencia_Datos

1. Contexto y preguntas de negocio

Colombia registró **125.284 víctimas de presunto homicidio** entre 2015 y 2024 según las cifras definitivas del Instituto Nacional de Medicina Legal. Para convertir ese registro en información útil para la prevención, construimos una bodega dimensional en PostgreSQL, la poblamos con un pipeline ETL en Python a partir del CSV crudo y la consultamos con SQL. La pregunta guía es: *¿Cuáles son los patrones temporales, geográficos y operacionales de los homicidios en Colombia que permiten identificar zonas de alto riesgo y factores para la prevención del delito?* De ella se derivan las preguntas abordadas:

#	Pregunta de negocio	Consulta / visualización
1	¿Cómo evolucionan los homicidios año a año y cuál es la variación interanual?	C1 · V1
2	¿Qué departamentos concentran los homicidios y cuáles crecieron entre 2015–19 y 2020–24?	C2 · V2, V3
3	¿Qué municipio concentra la violencia dentro de cada departamento?	C3 · V4
4	¿En qué días y franjas horarias se concentra el riesgo?	C4 · V5
5	¿Cómo se combinan sexo, edad, zona y mecanismo causal?	C5 · V6, V7
6	¿En qué escenarios mueren hombres y mujeres?	C6 · V8

2. Datos, ETL y bodega

El CSV fuente (33 columnas) presenta inconsistencias de captura que cambian entre años: la misma categoría aparece con distinta capitalización, espacios o puntuación (“Vía Pública”/“Vía pública”, “Corto punzante”/“Cortopunzante”, “(18:00 a 20:59)”/“18:00 a 20:59”), nombres geográficos variantes (“Bogotá D.C.”/“Bogotá, D.C.”) y vocabularios distintos (“Básica primaria” vs. “Educación básica primaria”). El ETL (*fase_b_etl.ipynb*) unifica variantes con una clave normalizada, aplica mapeos explícitos, deriva el departamento del código DANE del municipio, genera claves subrogadas y carga todo en una sola transacción con SQLAlchemy. La verificación final cuadra 125.284 hechos contra el CSV, sin claves huérfanas.

Todo el código, los notebooks y el CSV fuente están en el repositorio del proyecto: https://github.com/XEBAX10/PROYEC-1-CIencia_Datos. Las instrucciones para reproducirlo (git clone, pip install -r requirements.txt y Restart & Run All) están en el README.

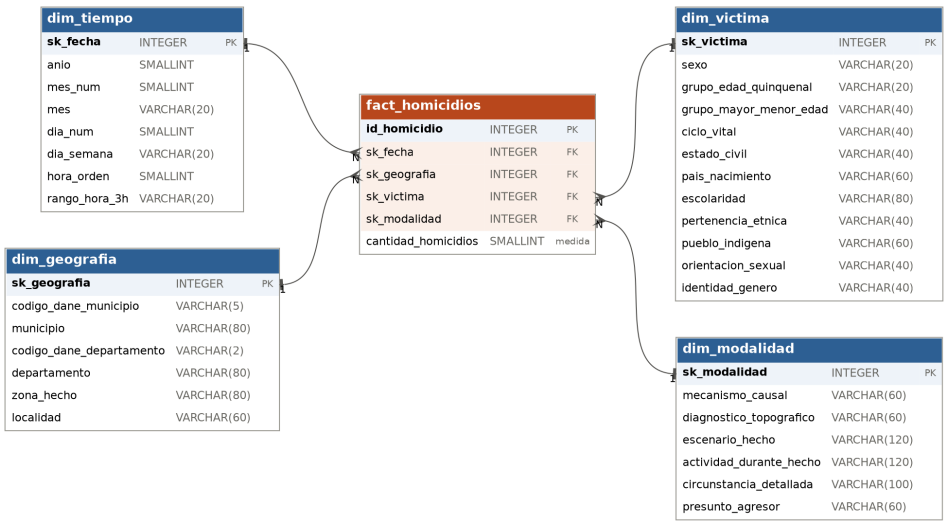


Figura 1. Modelo estrella: fact_homicidios (grano = una víctima) y dimensiones de tiempo, geografía, víctima y modalidad.

3. Hallazgos clave

Hallazgo 1 — La violencia subió de nivel en 2021 y se concentra en la noche del fin de semana

Tras cinco años estables (≈11.300–12.100 homicidios anuales) y un mínimo en 2020, los homicidios saltaron **16,9 % en 2021** y se sostuvieron sobre 13.900 en 2022–2024; 2024 cerró 21 % por encima de 2015. Dentro de la semana, el riesgo se concentra entre las 18:00 y las 03:00, con pico el **sábado de 21:00 a 23:59** (2.148 casos) y la madrugada del domingo; el domingo reúne el 21 % de los homicidios. Las franjas de 18:00 a 23:59 suman más casos que todas las franjas entre 03:00 y 14:59.

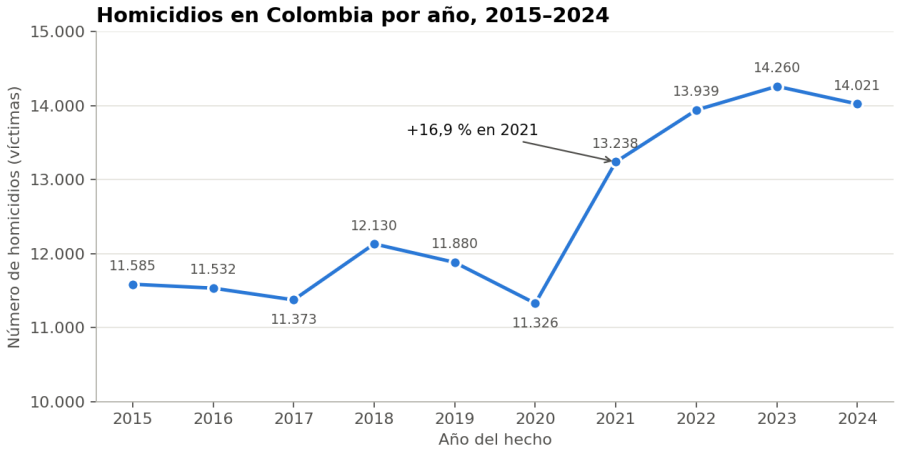


Figura 2 (V1). Homicidios por año, 2015–2024.

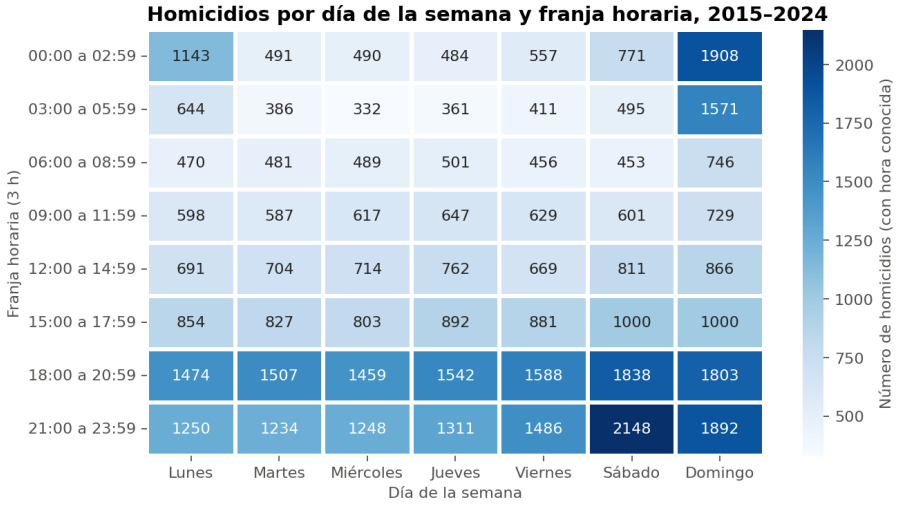


Figura 3 (V5). Homicidios por día y franja horaria (solo registros con hora conocida, 41 %).

Hallazgo 2 — Concentración en tres territorios, pero el crecimiento está en la periferia

Valle del Cauca (18,8 %), Antioquia (15,1 %) y Bogotá (9,3 %) concentran el 43 % de los homicidios, y en varios departamentos un solo municipio explica cerca de la mitad de los casos (Cartagena 59,8 %, Barranquilla 58,2 %, Cali 48,6 %). Sin embargo, estos grandes centros se mantuvieron estables o bajaron entre 2015–2019 y 2020–2024, mientras que **24 de 33 departamentos aumentaron**: Magdalena (+109 %), Cauca (+95 %), Sucre, Arauca, Bolívar (+52 %) y Atlántico (+33 %). En Cauca la violencia es además dispersa: su municipio líder apenas concentra el 16,8 %.

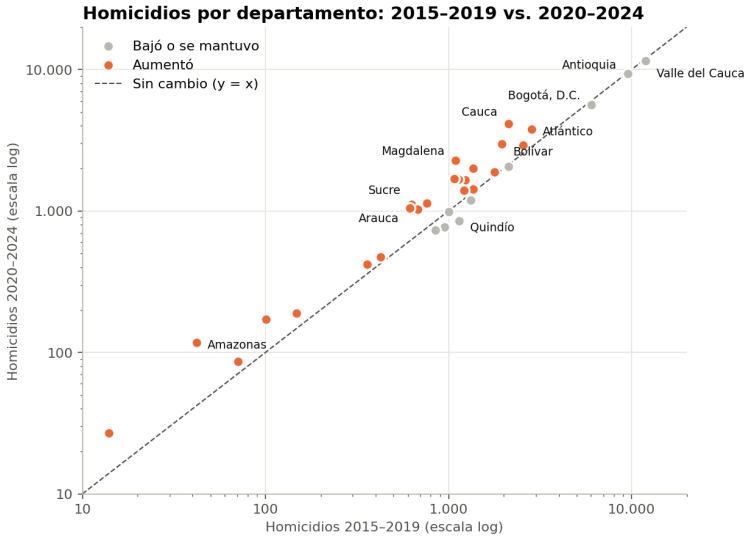


Figura 4 (V3). Homicidios por departamento en 2015–2019 vs. 2020–2024 (escala logarítmica). Puntos sobre la diagonal = aumento.

Hallazgo 3 — Dos perfiles de víctima: hombres jóvenes en la calle y mujeres en la vivienda

El 91,9 % de las víctimas son hombres y el **58,6 % tiene entre 18 y 34 años** (moda: 20–24 años). El perfil dominante es un hombre joven asesinado con arma de fuego en la vía pública (59,7 % de los hombres con escenario conocido). En las mujeres el patrón cambia: la **vivienda es el primer escenario (37,4 %)**, casi el triple que en hombres, el arma de fuego pesa menos (56,6 % vs. 75,5 %) y la asfixia es seis veces más frecuente (9,0 % vs. 1,4 %). Entre los agresores identificados de mujeres el más frecuente es el compañero permanente. Son mecanismos de contacto cercano asociados a violencia de pareja e intrafamiliar.

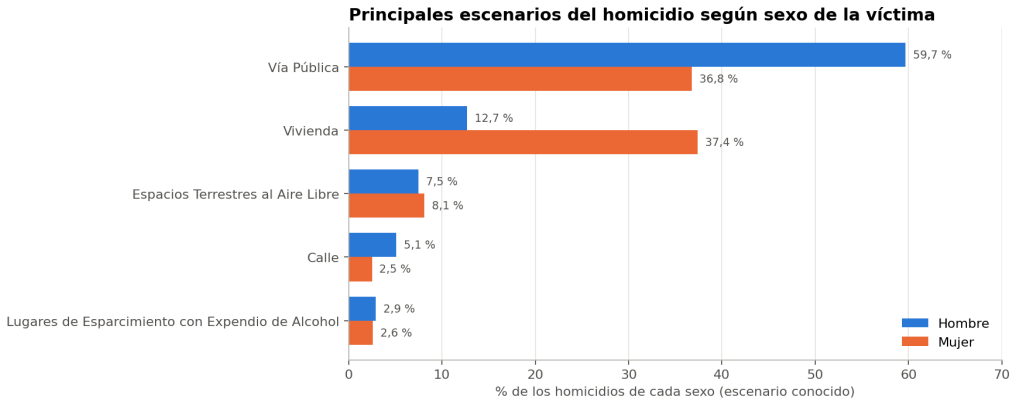


Figura 5 (V8). Principales escenarios del homicidio según sexo de la víctima.

4. Implicaciones para la prevención

- **Cuándo:** reforzar presencia y controles de porte de armas y consumo de alcohol en noches de viernes a domingo y en puentes festivos.
- **Dónde:** mantener la atención en Cali, Medellín, Bogotá y capitales del Caribe, y abrir estrategias rurales para Cauca, Magdalena, Sucre y Arauca, donde la violencia crece.
- **A quién / cómo:** programas de prevención para hombres de 15 a 34 años centrados en armas de fuego, y rutas de atención temprana de violencia de pareja para proteger a las mujeres.

5. Limitaciones

- **Datos faltantes:** la franja horaria falta en el 59 % de los registros (74 % en 2024), la circunstancia en el 65 % y el agresor en el 52 %; los hallazgos sobre esas variables describen solo la parte informada.
- **Sin tasas:** la bodega cuenta víctimas absolutas; sin población no puede compararse el riesgo per cápita entre departamentos de distinto tamaño.
- **Cambios de codificación:** las categorías cambiaron entre años; la normalización del ETL reduce el problema, pero algunas agrupaciones (escolaridad, circunstancia) implican decisiones de criterio.
- **Sin fecha exacta:** el CSV solo trae año, mes, día de la semana y franja; no permite analizar festivos concretos ni series diarias.
- **Cifras de presuntos homicidios:** reflejan necropsias de Medicina Legal, no fallos judiciales.

6. Próximos pasos

- Incorporar proyecciones de población del DANE para calcular tasas por 100.000 habitantes por municipio y año.

- Agregar una dimensión de fecha calendario si se obtiene la fecha del hecho, para estudiar festivos y eventos.
- Modelar la probabilidad de homicidio con arma de fuego o en vivienda según perfil y territorio (P2/P3), e imputar o modelar los faltantes de hora.
- Construir un tablero interactivo sobre la bodega para seguimiento de zonas de alto riesgo.