Homicidios en Colombia 2015–2024: limpieza de datos y modelos predictivos

Informe final — Proyectos 2 y 3 (Análisis, Limpieza y Modelado)

Alejandra Osorio Giraldo (2266128)

Sebastián Barco (2380599)

Santiago Montoya (2380372)

Laura Rivera (2380712)

Ciencia de Datos
Universidad del Valle — sede Tuluá
Octubre 2026

Repositorio: github.com/XEBAX10/PROYEC-1-CIencia_Datos

1. Contexto del dataset y pregunta de negocio

Se trabaja con **Presuntos Homicidios. Colombia, 2015 a 2024. Cifras definitivas**, del Instituto Nacional de Medicina Legal y Ciencias Forenses (datos.gov.co): **125.284 víctimas × 33 columnas** con datos de la víctima (sexo, edad, estado civil, escolaridad), del lugar (departamento, municipio, zona, escenario), del momento (año, mes, día, franja horaria) y del hecho (mecanismo causal, actividad, circunstancia). Es el mismo dataset del Proyecto 1, donde se construyó una bodega dimensional y se describieron los patrones temporales y geográficos. En estos proyectos se limpia a fondo y se construyen modelos predictivos.

> **Preguntas de negocio.** (1) ¿Se puede anticipar, con las características de la víctima, el lugar y el momento, si un homicidio será cometido con **arma de fuego**? Responderla ayuda a priorizar controles de porte de armas en los perfiles y zonas de mayor riesgo. (2) ¿Qué **perfiles de municipios** existen según su patrón de violencia, para diseñar estrategias de prevención diferenciadas?

La pregunta (1) es una **clasificación supervisada binaria** (`es_arma_fuego`: 74,2 % de los casos) y la (2) es un problema de **agrupamiento no supervisado** (K-Means sobre municipios).

2. Resumen del análisis exploratorio (Fase A)

El dataset casi no trae variables numéricas, así que se derivaron algunas de las categorías: edad aproximada (punto medio del grupo quinquenal), hora aproximada, día y mes como número, y un resumen por municipio (homicidios, % arma de fuego, % mujeres, % rural). Sobre ellas se hicieron histogramas, boxplots, correlaciones de Pearson y Spearman, un violín y un Pareto. Los tres hallazgos principales son:

- **Concentración territorial y urbana.** Valle del Cauca, Antioquia y Bogotá suman el 43,1 % de los homicidios, y 14 de los 33 departamentos explican el 80 %. Con Spearman, los municipios con más homicidios son menos rurales ($\rho = -0{,}34$), usan más el arma de fuego ($\rho = 0{,}38$) y tienen víctimas más jóvenes ($\rho = -0{,}35$).
- **Víctima típica: hombre joven con arma de fuego.** El 91,9 % son hombres, el 58,6 % tiene entre 18 y 34 años y el 74 % muere por arma de fuego. La mediana de edad con arma de fuego en hombres es 27 años, frente a 37 con objeto contundente o asfixia.
- **Aumento desde 2021, de noche y en fin de semana.** El país pasó de unos 11.500 casos por año a más de 13.000 desde 2021 (pico de 14.260 en 2023). Sábado y domingo reúnen el 36,9 % de los casos, y el 42 % de los casos con hora informada ocurre entre las 18:00 y las 23:59.

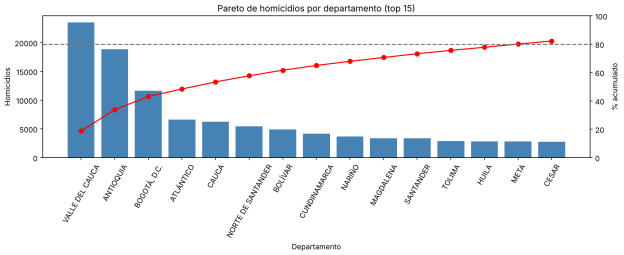


Figura 1. Pareto de homicidios por departamento.

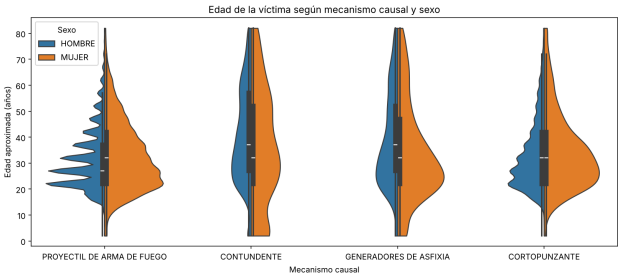


Figura 2. Edad de la víctima según mecanismo y sexo.

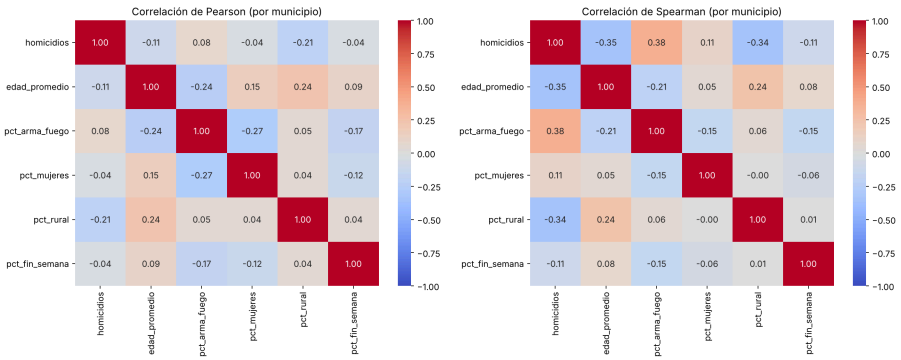


Figura 3. Correlación de Pearson y Spearman por municipio. Spearman muestra relaciones más claras porque Pearson se distorsiona con los extremos (Bogotá, Cali).

A nivel de víctima, todas las correlaciones numéricas son casi cero ($|r| \leq 0{,}04$): los patrones del dataset están en las **variables categóricas**, por lo que los modelos se construyeron sobre ellas codificadas.

3. Técnicas de limpieza y normalización (Fase B)

El diagnóstico mostró que los faltantes no venían como nulos sino como texto ("*Sin información*" en 525.641 celdas, "*No había sido implementada*", "*Por determinar*", "*No aplica*"), que no hay duplicados, y que había muchas inconsistencias de escritura: mayúsculas, espacios, vocabularios que cambiaron entre años y municipios con dos nombres. El pipeline final se aplica sobre un único DataFrame y deja **124.914 filas × 108 columnas, 0 nulos y 0 duplicados**, guardadas en `datos_limpios.parquet`.

Paso	Técnica y decisión	Justificación
Normalización de texto	Mayúsculas, espacios y puntuación unificados; vocabularios equivalentes ("Corto punzante" = "Cortopunzante"); municipio tomado del código DANE. Estado civil pasa de 11 a 5 valores, Escenario de 72 a 40 y Mecanismo de 24 a 15.	Eran la misma categoría escrita distinto; sin esto los conteos y el One-Hot quedan partidos.
Eliminación	8 columnas con más del 50 % de nulos o "no implementada" (localidad, circunstancia, agresor, orientación sexual…), 3 redundantes o sin variación, y 370 filas (0,3 %) sin municipio o sin mecanismo.	Imputar más de la mitad de una columna sería inventar datos; sin mecanismo no hay variable objetivo.
Nulos — moda	Escenario, zona, mes, día, ciclo vital, grupo de edad, país y ancestro (0,02 %–8,7 % de nulos).	Son categóricas con pocos faltantes: la moda casi no cambia la distribución.
Nulos — mediana	Escolaridad ordinal (21 %) → nivel 2 (básica primaria).	Ordinal y sesgada: la media (2,45) no corresponde a ningún nivel.
Nulos — categoría propia	"SIN INFORMACIÓN" en franja horaria (59 %), actividad, estado civil y pertenencia étnica.	Con la moda se inventarían hasta 73.901 horas; la ausencia puede ser informativa para el modelo.
Outliers (IQR y Z-score)	IQR: 4,5 % de víctimas mayores de 59,5 años. Z-score: 6 ciudades con $\|z\| > 3$. **Se conservan.**	Son datos reales; las grandes ciudades reúnen el 30 % de los

		casos. Su efecto se reduce con log y RobustScaler.
Ordinal Encoding	Grupo de edad (18 niveles), ciclo vital (6), escolaridad (8), mes y día.	Tienen un orden natural que One-Hot perdería.
One-Hot (`drop_first=True`)	Sexo, zona, escenario, franja horaria, departamento, estado civil y actividad → 78 columnas.	Son nominales; `drop_first` evita multicolinealidad. Departamento (33) en vez de municipio (1.000+).
Transformación log	`log(1 + homicidios del municipio)`: la asimetría pasa de 16,2 a 0,46.	La variable estaba muy sesgada a la derecha.
Escalado	Se compararon Min-Max, Z-score y RobustScaler. El parquet se guarda **sin escalar**.	El escalado se ajusta solo con el conjunto de entrenamiento en la Fase C, para evitar data leakage.

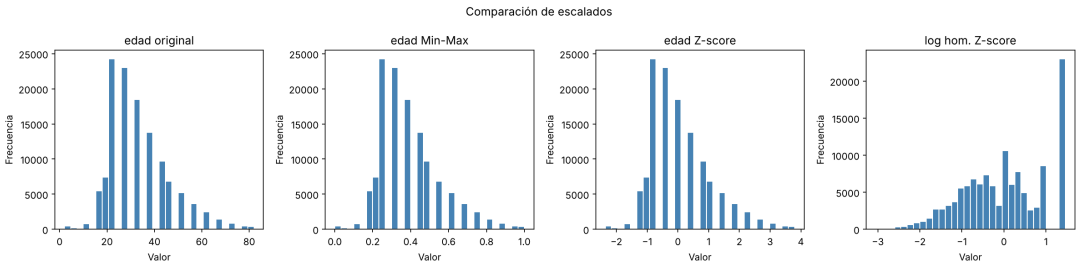


Figura 4. Comparación de escalados: cambia la escala, no la forma de la distribución.

4. Modelos entrenados y comparación de desempeño (Fase C)

4.1 Diseño experimental

- **Variables:** 84 en total, 6 numéricas u ordinales (año, grupo de edad, escolaridad, mes, día, log de homicidios del municipio) y 78 One-Hot. Objetivo: `es_arma_fuego`.
- **División:** `train_test_split` 80/20 estratificado (99.931 / 24.983 filas). El `StandardScaler` se ajusta solo con el conjunto de entrenamiento, y todas las métricas se calculan en el de **prueba**.
- **Desbalance:** `class_weight="balanced"` en los 3 modelos, porque un modelo que siempre dijera "arma de fuego" tendría 74 % de accuracy sin aprender nada.
- **Modelos:** Regresión Logística, Árbol de Decisión (profundidad 10) y Random Forest (200 árboles, profundidad 15).

4.2 Tabla comparativa (conjunto de prueba)

Modelo	Accuracy	Precision	Recall	F1	F1 macro	ROC-AUC	Acc. train
Regresión Logística	0,669	0,845	0,680	0,753	0,627	0,716	0,669
Árbol de Decisión	0,683	0,825	0,727	0,773	0,624	0,689	0,695
Random Forest	**0,698**	**0,842**	**0,730**	**0,782**	**0,645**	**0,732**	**0,714**

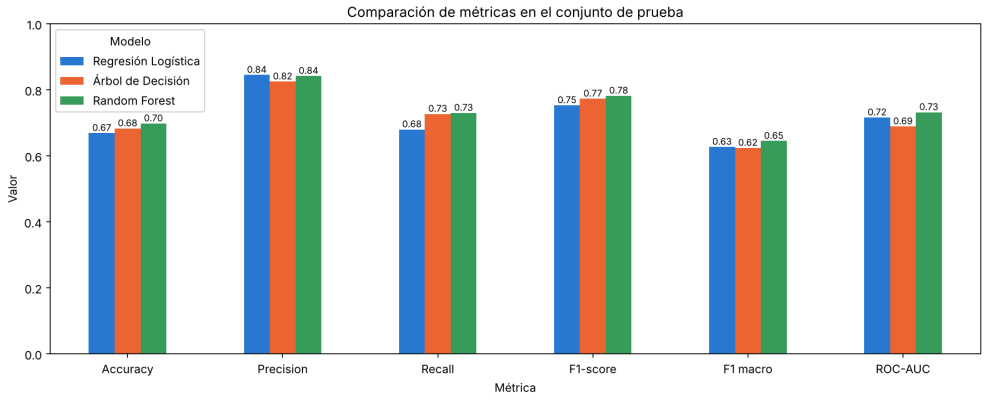


Figura 5. Comparación de métricas de los tres modelos.

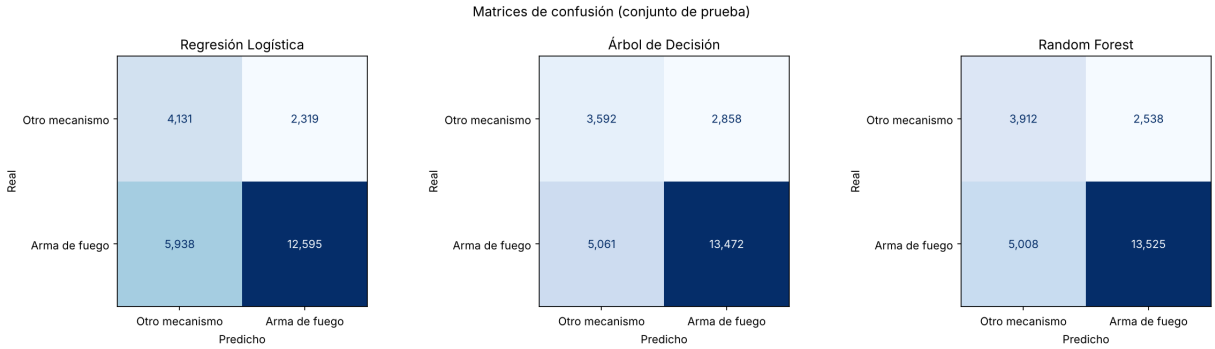


Figura 6. Matrices de confusión. Random Forest: 3.912 de 6.450 casos de otro mecanismo (61 %) y 13.525 de 18.533 de arma de fuego (73 %) bien clasificados.

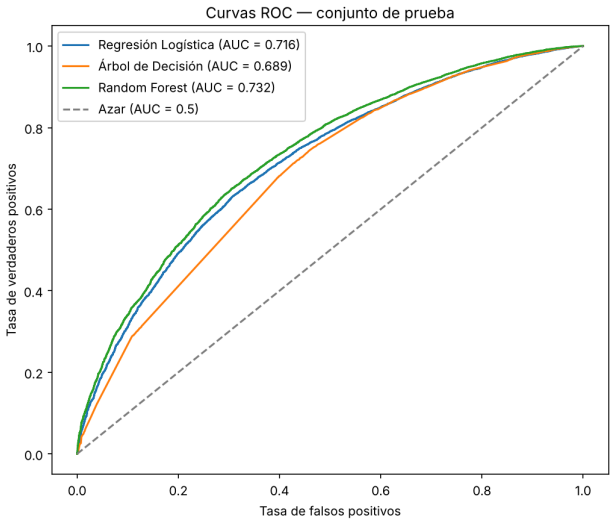


Figura 7. Curvas ROC.

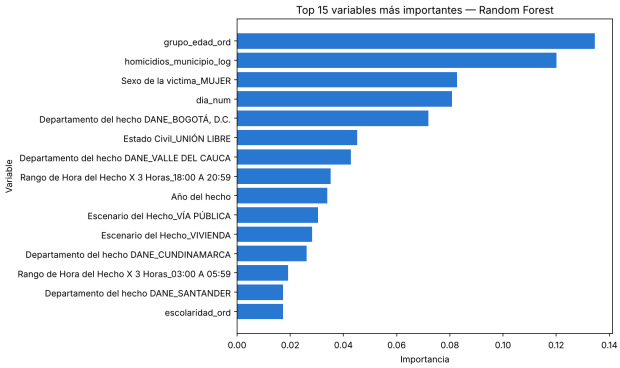


Figura 8. Variables más importantes (Random Forest).

> **Modelo elegido: Random Forest. Por precisión:** es el mejor en 5 de las 6 métricas (F1 0,782, F1 macro 0,645, AUC 0,732); solo en precision la Regresión Logística lo supera por 0,003. **Por generalización:** la brecha entre entrenamiento y prueba es de 1,6 puntos, así que no hay sobreajuste. **Por interpretabilidad:** sus variables más importantes son la edad, los homicidios del municipio, el sexo, el día, el departamento y el escenario, coherentes con la Fase A. La Regresión Logística queda como alternativa simple, a 1,6 puntos de AUC.

4.3 Modelo no supervisado: K-Means sobre municipios

Se agruparon los **464 municipios con 30 o más homicidios** usando 5 variables escaladas: log de homicidios, % arma de fuego, % mujeres, % rural y edad promedio. Al probar k entre 2 y 8, el Silhouette fue máximo en **k = 4**: **Silhouette 0,219** y **Davies-Bouldin 1,40**. Los grupos se solapan algo, como es habitual en datos sociales, pero tienen perfiles claros.

Segmento	Perfil	Ejemplos	Estrategia sugerida
Grandes ciudades con arma de fuego (122 mun.)	Mediana de 314 casos, 82 % arma de fuego, 22 % rural, edad 32 años; 73 % de los casos	Bogotá, Cali, Medellín, Barranquilla, Cúcuta	Control de armas y prevención juvenil urbana
Rural con más mujeres y víctimas mayores (104)	56 % rural, 12 % mujeres, edad 37 años	San Vicente del Caguán, Puerto Gaitán	Violencia intrafamiliar, presencia rural
Ciudades intermedias con arma blanca (60)	Solo 52 % arma de fuego, 21 % rural	Bucaramanga, Ibagué, Popayán, Pasto	Riñas y arma cortopunzante
Rural con arma de fuego (178)	57 % rural, 80 % arma de fuego	Ituango, El Tambo, Suárez, Arauquita	Zonas con presencia de grupos armados

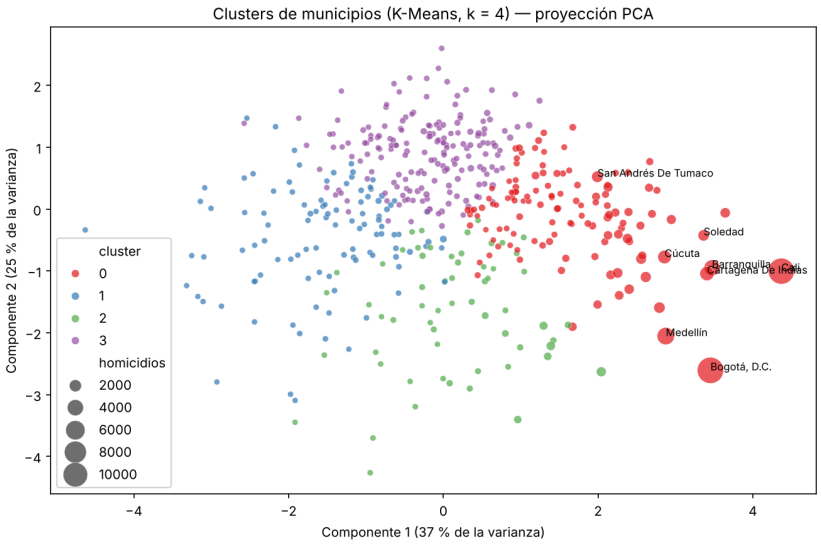


Figura 9. Clusters de municipios proyectados con PCA (62 % de la varianza en 2 componentes).

5. Conclusiones y posibles mejoras

Conclusiones

- **Análisis:** el homicidio en Colombia está concentrado en pocos territorios urbanos, afecta sobre todo a hombres jóvenes con arma de fuego y creció desde 2021.
- **Limpieza:** la calidad del dato fue el mayor reto. La mitad de las columnas más ricas (agresor, circunstancia) tenía más del 50 % de faltantes y muchas categorías estaban escritas de varias formas. Normalizar y documentar cada decisión fue clave para que los modelos fueran confiables.
- **Modelado:** el Random Forest predice el mecanismo con un poder **moderado** (AUC 0,73, F1 0,78). Es útil para priorizar perfiles de riesgo, pero no para decidir caso por caso. El K-Means separa 4 tipos de municipio que piden estrategias de prevención distintas, y no una política única para todo el país.

Posibles mejoras

- **Más datos:** variables por municipio como población (para usar tasas por 100.000 habitantes y no conteos), presencia de grupos armados, pobreza y fuerza pública.
- **Más features:** recuperar la circunstancia y el agresor en los años en que sí existen, e incluir días festivos y quincenas.
- **Hiperparámetros:** `GridSearchCV` con validación cruzada estratificada; ajustar el umbral de decisión según el costo de cada error.
- **Otros algoritmos:** Gradient Boosting (XGBoost, LightGBM) para clasificación; DBSCAN o clustering jerárquico para validar los segmentos.

6. Repositorio del proyecto

> El código, los notebooks, los datos limpios y las figuras están disponibles en:
> **https://github.com/XEBAX10/PROYEC-1-CIencia_Datos**