PROYECTOS 2 Y 3 · CIENCIA DE DATOS

Homicidios en Colombia 2015–2024: limpieza de datos y modelos predictivos

Medicina Legal · 125.284 víctimas · 33 variables

Alejandra Osorio Giraldo · Sebastián Barco · Santiago Montoya · Laura Rivera

Universidad del Valle — sede Tuluá · Octubre 2026

CONTEXTO

Pregunta de negocio

Mismo dataset del Proyecto 1: **Presuntos Homicidios 2015–2024** (datos.gov.co). Ahora lo limpiamos a fondo y le construimos modelos.

1. ¿Se puede anticipar, con datos de la víctima, el lugar y el momento, si un homicidio será con **arma de fuego**?
→ Clasificación supervisada · priorizar control de armas

2. ¿Qué **perfiles de municipios** existen según su patrón de violencia?
→ Clustering no supervisado · prevención diferenciada

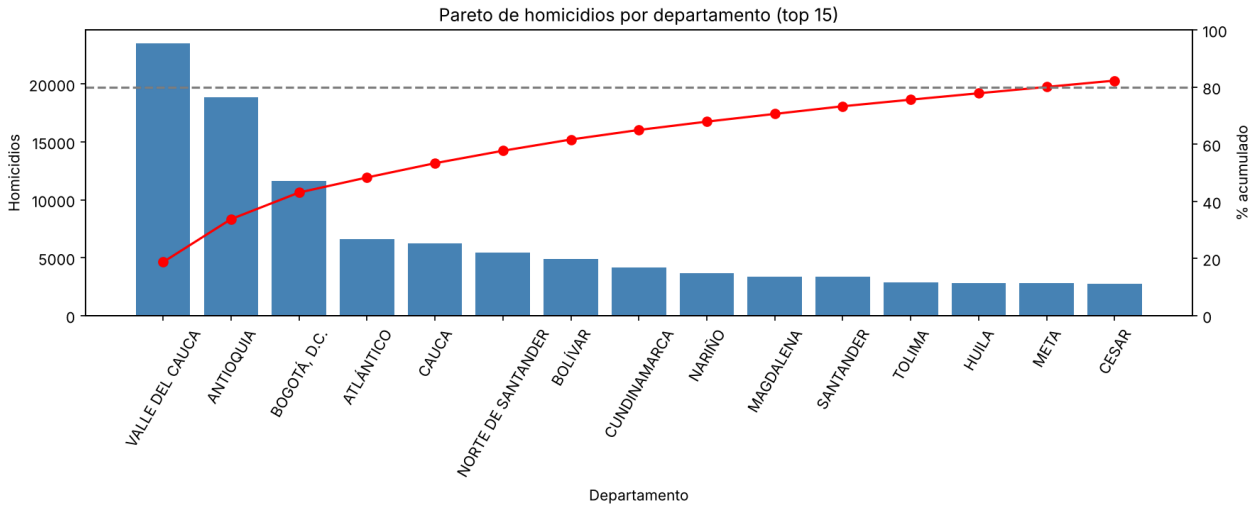
125.284
víctimas registradas

74,2 %
murieron por arma de fuego (variable objetivo)

4
modelos: 3 supervisados + K-Means

FASE A · ANÁLISIS EXPLORATORIO

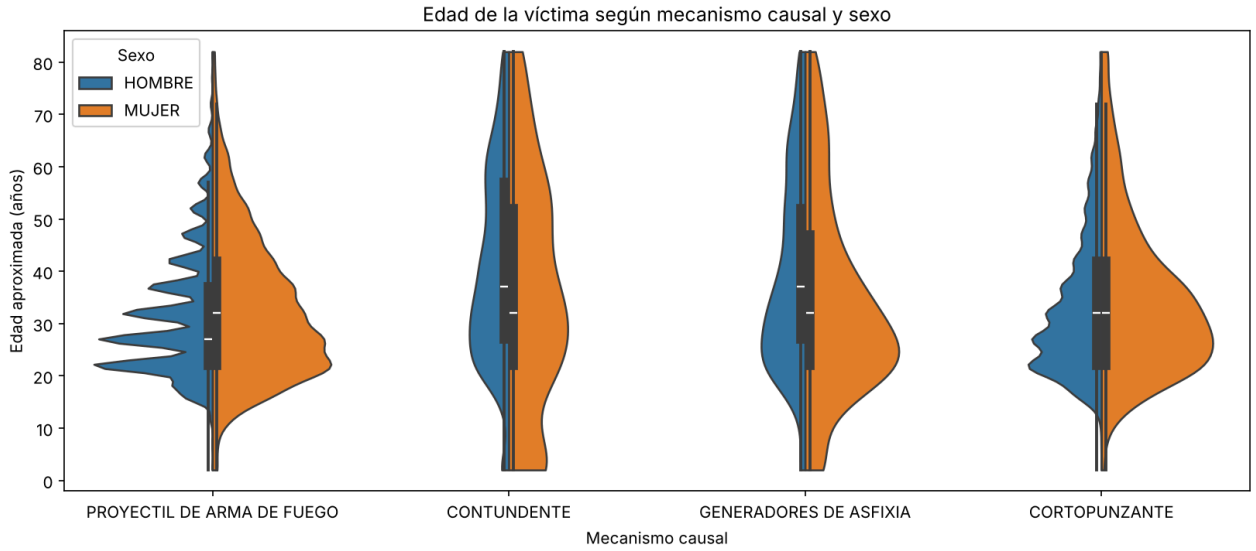
La violencia está concentrada



- **Valle, Antioquia y Bogotá** suman el **43,1 %** de los homicidios.
- **14 de 33** departamentos explican el 80 %.
- Por Spearman, los municipios con más casos son más **urbanos** ($\rho = -0{,}34$) y usan más el **arma de fuego** ($\rho = 0{,}38$).
- Desde 2021 el país pasó de ~11.500 a **más de 13.000** casos por año.

FASE A · ANÁLISIS EXPLORATORIO

La víctima típica: hombre joven, arma de fuego



- **91,9 %** hombres; **58,6 %** entre 18 y 34 años.
- Los hombres asesinados con arma de fuego tienen una mediana de **27 años**, frente a 37 con objeto contundente o asfixia.
- En las mujeres cambian el escenario y el mecanismo: más vivienda y más arma blanca.
- El **42 %** de los casos con hora informada ocurre entre las 18:00 y las 23:59.

FASE B · LIMPIEZA Y NORMALIZACIÓN

De datos sucios a un dataset listo para modelar

525.641

celdas "Sin información" convertidas en nulos

72 → 40

escenarios tras unificar la escritura (mecanismo: 24 → 15)

124.914 × 108

dataset final · 0 nulos · 0 duplicados

- **Normalización de texto:** mayúsculas, espacios y comas; "Cali" = "Santiago de Cali" a partir del código DANE.
- **Columnas eliminadas** con más del 50 % de nulos: localidad, circunstancia, agresor y 5 más.
- **Outliers:** se detectaron con IQR y Z-score y **se conservan**, porque son edades reales y grandes ciudades.
- **Log(1 + x)** en homicidios por municipio: la asimetría baja de 16,2 a 0,46.

FASE B · DECISIONES JUSTIFICADAS

Cada técnica según el tipo de variable

Técnica	Dónde	Por qué
Moda	Escenario, zona, mes, día, grupo de edad (< 10 % nulos)	Categóricas con pocos faltantes
Mediana	Escolaridad ordinal (21 % nulos)	La media (2,45) no es un nivel real
"SIN INFORMACIÓN"	Franja horaria (59 %), actividad, estado civil	La moda inventaría 73.901 horas
Ordinal Encoding	Grupo de edad, ciclo vital, escolaridad	Tienen orden natural
One-Hot (drop_first)	Sexo, zona, escenario, hora, departamento… (78 columnas)	Nominales; evita multicolinealidad
Escalado	Min-Max, Z-score y RobustScaler comparados	Se aplica **después del split** (sin leakage)

FASE C · MODELOS SUPERVISADOS

Random Forest es el mejor modelo

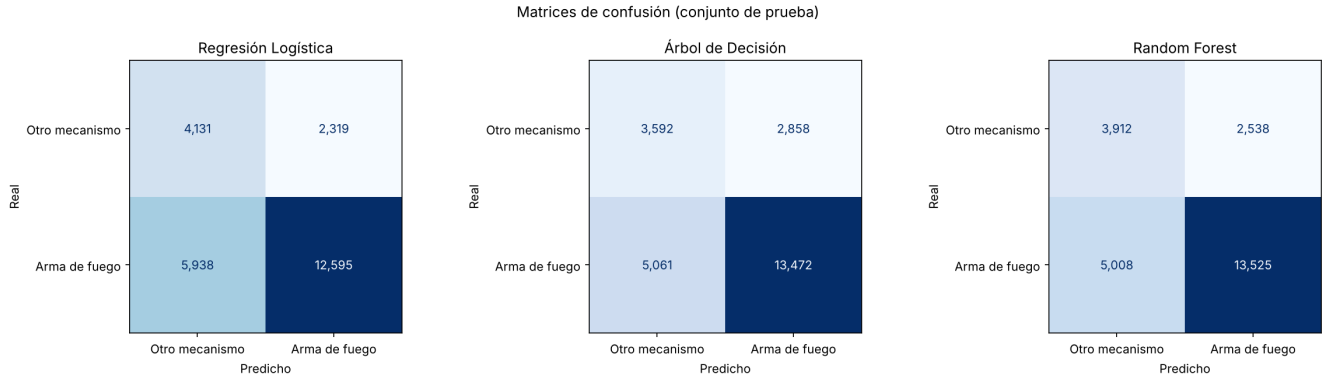
Split 80/20 estratificado · StandardScaler ajustado solo con train · class_weight="balanced" · métricas en el conjunto de **prueba**

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	Acc. train
Regresión Logística	0,669	0,845	0,680	0,753	0,716	0,669
Árbol de Decisión	0,683	0,825	0,727	0,773	0,689	0,695
Random Forest	**0,698**	**0,842**	**0,730**	**0,782**	**0,732**	**0,714**

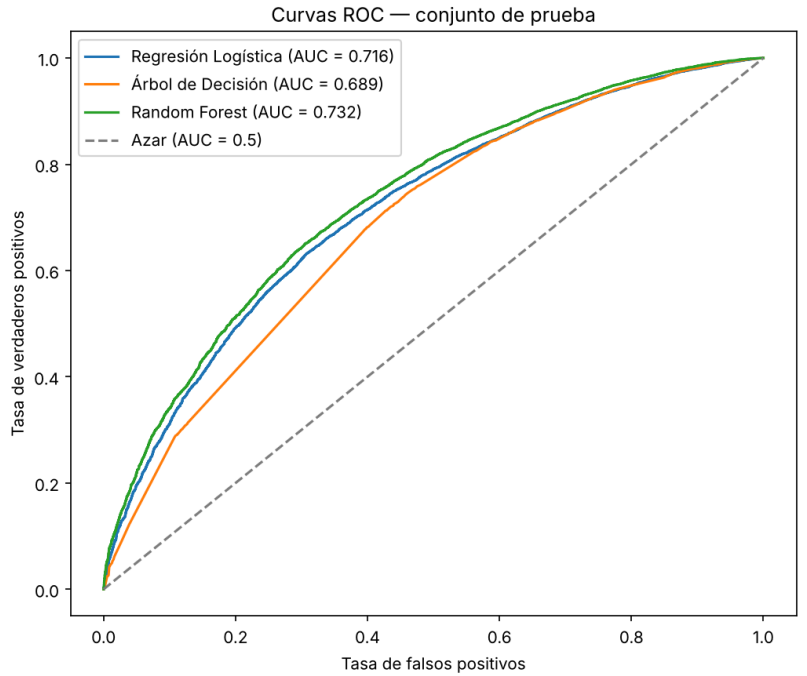
> **¿Por qué no basta la accuracy?** Un modelo que siempre dijera "arma de fuego" tendría 0,742, pero no detectaría **ningún** caso de otro mecanismo. Por eso se comparan F1 y ROC-AUC.

FASE C · RESULTADOS

Matrices de confusión y curva ROC

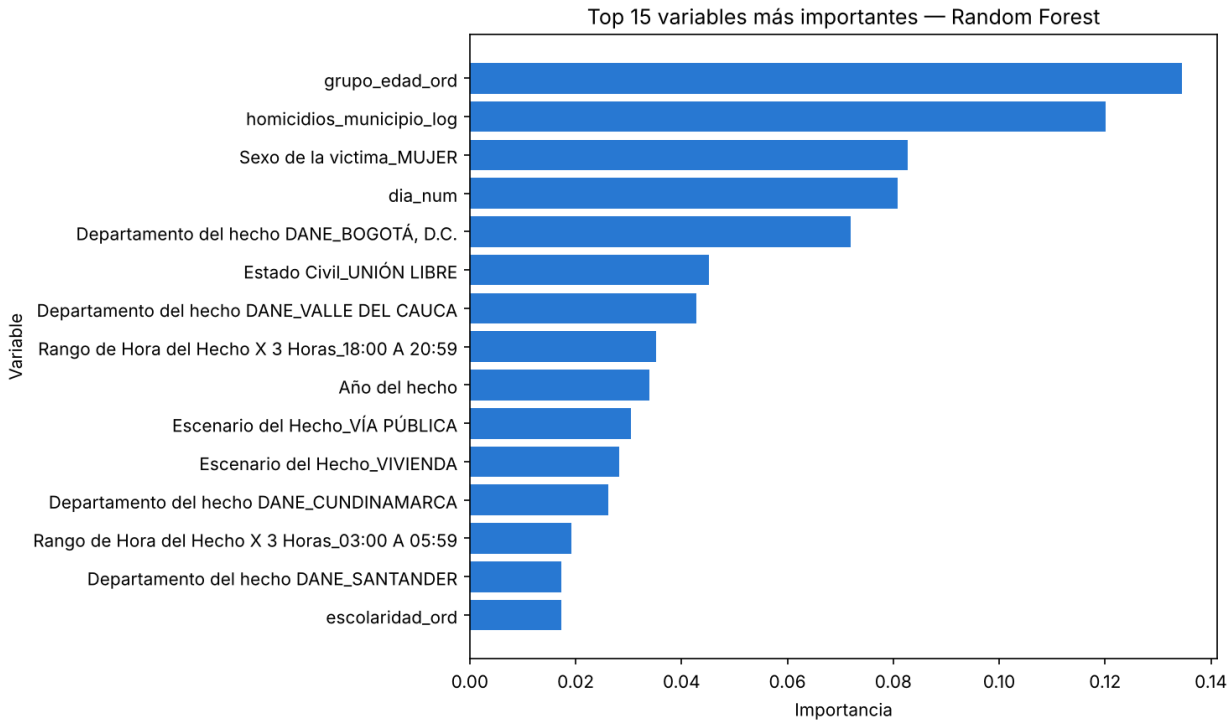


Random Forest: acierta el **61 %** de los casos de otro mecanismo y el **73 %** de arma de fuego. Brecha entre train y test de solo 1,6 puntos, **sin sobreajuste**.



FASE C · INTERPRETACIÓN

¿Qué variables pesan más?



- **Edad:** los jóvenes mueren más por arma de fuego.
- **Homicidios del municipio:** en las grandes ciudades domina el arma de fuego.
- **Sexo:** las mujeres mueren más por arma blanca o asfixia.
- **Departamento y escenario:** Bogotá tiene más arma blanca y el Valle más arma de fuego; vía pública frente a vivienda.

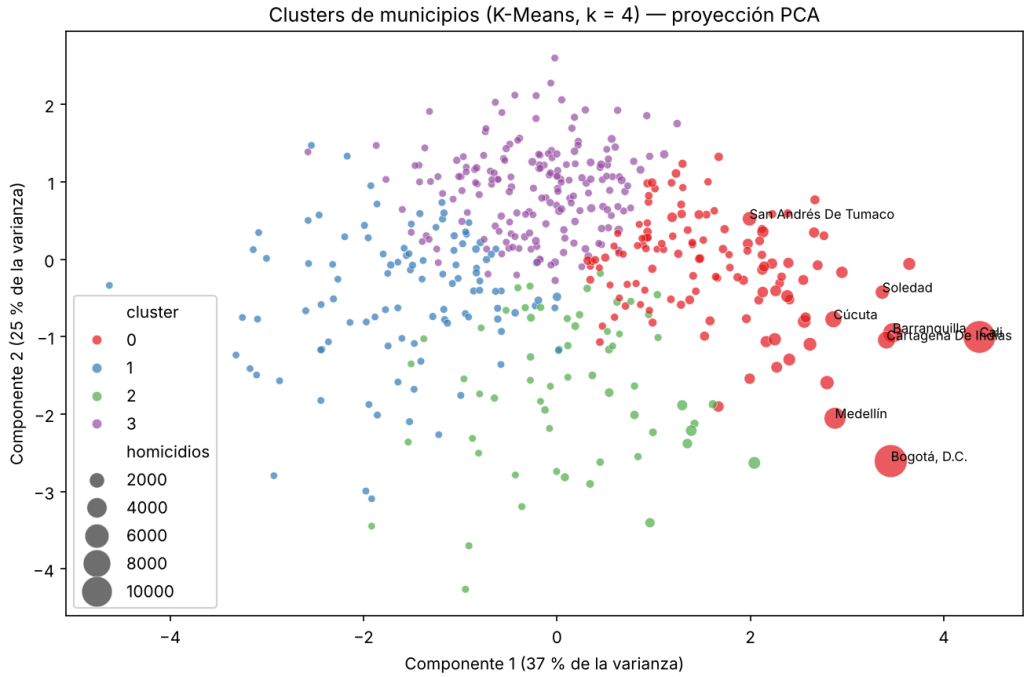
> Coincide con los hallazgos de la Fase A.

FASE C · NO SUPERVISADO

K-Means: 4 tipos de municipio

464 municipios (≥ 30 casos) · 5 variables escaladas · k = 4 por Silhouette · **Silhouette 0,219 · Davies-Bouldin 1,40**

Segmento	Perfil	Ejemplos
Grandes ciudades	82 % arma de fuego · 73 % de los casos	Bogotá, Cali, Medellín
Rural, más mujeres	56 % rural · 12 % mujeres · 37 años	San Vicente del Caguán
Intermedias, arma blanca	Solo 52 % arma de fuego	Bucaramanga, Ibagué, Pasto
Rural, arma de fuego	57 % rural · 80 % arma de fuego	Ituango, El Tambo, Suárez



FASE D · CIERRE

Conclusiones y mejoras

Conclusiones

- El homicidio se concentra en **ciudades grandes**, en **hombres jóvenes** y con **arma de fuego**, y creció desde 2021.
- La **calidad del dato** fue el mayor reto: las variables más ricas tenían más del 50 % de nulos.
- **Random Forest** tiene un poder predictivo moderado (AUC 0,73, F1 0,78): sirve para priorizar perfiles, no para decidir caso por caso.
- Los **4 segmentos** piden políticas de prevención distintas.

Mejoras

- **Más datos:** población (tasas por 100 mil), presencia de grupos armados, pobreza.
- **Más features:** festivos y quincenas; agresor y circunstancia en los años con datos.
- **Hiperparámetros:** GridSearchCV con validación cruzada y ajuste del umbral.
- **Otros algoritmos:** Gradient Boosting, DBSCAN, clustering jerárquico.

¡Gracias!

¿Preguntas?

Repositorio: github.com/XEBAX10/PROYEC-1-CIencia_Datos